CLASS SWITCHING

Consideriamo ora il caso in cui ci si debba autenticare prima di accedere al DB.

- Il workload di autenticazione ha caratteristiche diverse dal workload di interrogazione del DB.
- Necessario meccanismo per rappresentare il fatto che il workload associato ad un utente può cambiare nel tempo.
- Estensione della rappresentazione in classi con l'aggiunta di probabilità di switching tra le classi

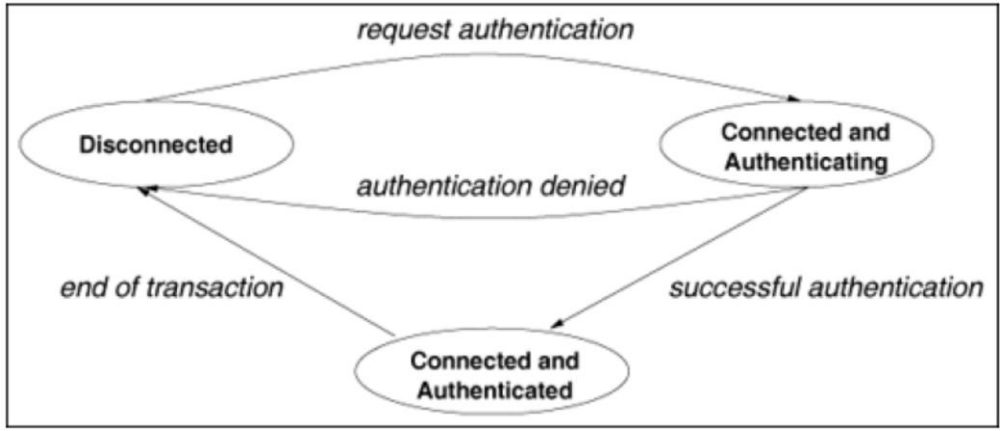

MODELLI QN

Diamo ora una definizione più formale di QN.

Una QN è una collezione di *K* code interconnesse.

- Con il termine *coda* o *stazione* identifichiamo sia la vera e propria fila d'attesa che la risorsa che fornisce servizio alla richiesta
- Le richieste si muovono da una coda all'altra finché non completano la loro esecuzione
- Le richieste possono essere raggruppate in classi
- In alcuni casi, le richieste possono cambiare classe

I parametri di input di una coda sono divisi in due gruppi

- **Intensità di workload.** Questi parametri forniscono un'indicazione del carico del sistema. Possono essere misurati *in termini di tassi di arrivo per classi aperte* o *in termini di popolazione per classi chiuse*.
- **Service demands.** Questi parametri specificano il tempo di servizio medio totale fornito da una specifica risorsa ad una data classe di richieste. I service demand solitamente non dipendono dal carico del sistema, ma questo può accadere in alcuni casi.

MODELLI QN (2)

Le classi di workload possono essere caratterizzate come:

- ***Transaction***. Classe aperta, dove l'intensità è rappresentata da un tasso di arrivi.
- ***Batch***. Classe chiusa, dove l'intensità è rappresentata dal numero di clienti di quella classe all'interno della QN
- ***Interactive***. Classe chiusa usata per modellare situazioni in cui le richieste sono inviate da un numero fissato M di macchine client. L'intensità del workload è rappresentata dal numero di terminali M e dal *think time* medio Z

NOTAZIONE DI UNA QN

Una coda in una QN è specificata dal tipo (load independent, load dependent, delay) e dalla disciplina di accodamento (FCFS, RR, …).

Utilizzeremo la seguente notazione per esprimere le caratteristiche di una QN:

- $\boldsymbol{K}$: numero di code in una QN
- $\boldsymbol{R}$: numero di classi in una QN
- $\vec{\boldsymbol{\lambda}} = (\lambda_1, \dots, \lambda_R)$: vettore dei tassi di arrivo per una QN aperta multi-classe. $\lambda_r (r = 1, \dots, R)$ è il tasso medio degli arrivi degli utenti di classe r
- $\vec{\boldsymbol{N}} = (N_1, \dots, N_R)$: vettore della popolazione per una QN chiusa multi-classe. $N_r (r = 1, \dots, R)$ è il numero dei clienti di classe r
- $\boldsymbol{D_{i,r}}$: service demand dei clienti di classe r presso la coda i
- $\boldsymbol{Prior(r)}$: priorità della classe r. Le priorità sono numerate da 1 a P, dove 1 è la priorità più alta
- $\boldsymbol{X_{0,r}}$: throughput di richieste di classe r
- $\boldsymbol{R_{0,r}}$: tempo di risposta per richieste di classe r

ESEMPIO DI CARATTERIZZAZIONE DI UNA QN

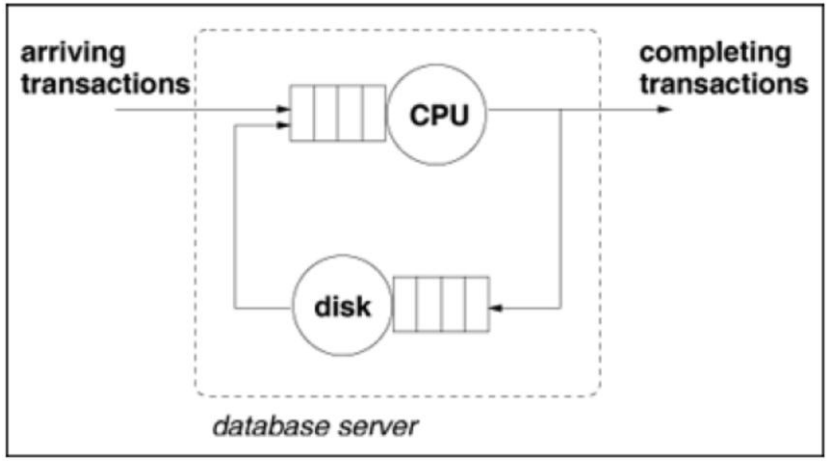

Classe di servizio	Percentuale sul totale	Tempo medio di CPU (sec)	Numero medio di I/O
Semplice	45%	0.04	5.5
Medio	25%	0.18	28.9
Complesso	30%	1.20	85.0

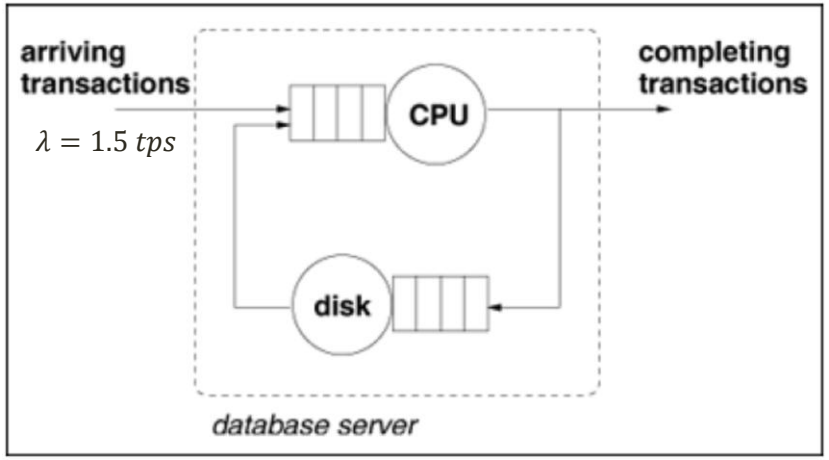

Classe di servizio	Percentuale sul totale	Tempo medio di CPU (sec)	Numero medio di I/O
Semplice	45%	0.04	5.5
Medio	25%	0.18	28.9
Complesso	30%	1.20	85.0

K=; R=;			Tipo di Coda / Politica di Scheduling	
			XX/YY	XX/YY
Classe (r)	**Tipo**	**λ_r (tps)**	$D_{CPU,r}\ (sec)$	$D_{Disk,r}\ (sec)$
1 (semplice)				
2 (medio)				
3 (complesso)				

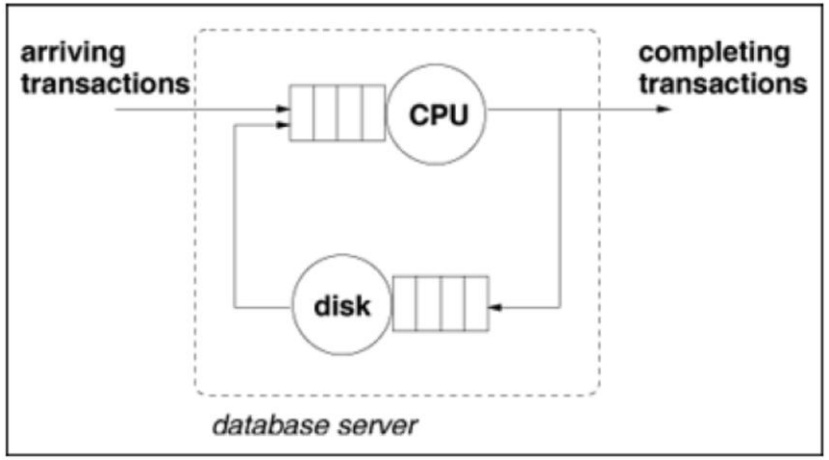

Classe di servizio	Percentuale sul totale	Tempo medio di CPU (sec)	Numero medio di I/O
Semplice	45%	0.04	5.5
Medio	25%	0.18	28.9
Complesso	30%	1.20	85.0

K=; R=;			Tipo di Coda / Politica di Scheduling	
			XX/YY	XX/YY
Classe (r)	**Tipo**	**λ_r (tps)**	$D_{CPU,r}\ (sec)$	$D_{Disk,r}\ (sec)$
1 (semplice)	Aperto/Chiuso?	0.675		
2 (medio)	Aperto/Chiuso?	0.375		
3 (complesso)	Aperto/Chiuso?	0.450		

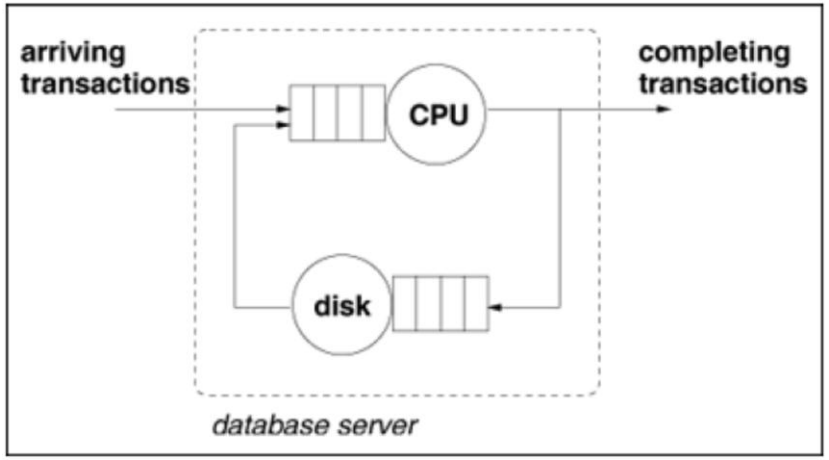

Classe di servizio	Percentuale sul totale	Tempo medio di CPU (sec)	Numero medio di I/O
Semplice	45%	0.04	5.5
Medio	25%	0.18	28.9
Complesso	30%	1.20	85.0

K=; R=; Open QN			Tipo di Coda / Politica di Scheduling	
			XX/YY	XX/YY
Classe (r)	**Tipo**	λ_r **(tps)**	$D_{CPU,r}\ (sec)$	$D_{Disk,r}\ (sec)$
1 (semplice)	Aperto	0.675		
2 (medio)	Aperto	0.375		
3 (complesso)	Aperto	0.450		

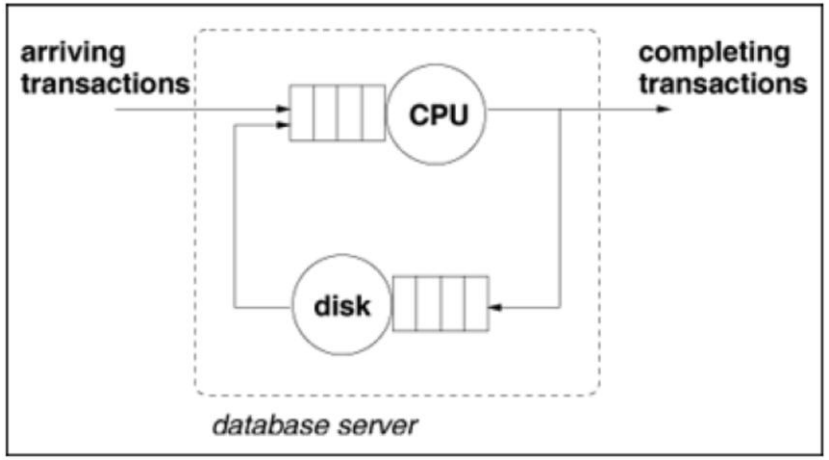

Classe di servizio	Percentuale sul totale	Tempo medio di CPU (sec)	Numero medio di I/O
Semplice	45%	0.04	5.5
Medio	25%	0.18	28.9
Complesso	30%	1.20	85.0

K=2; R=3; Open QN			Tipo di Coda / Politica di Scheduling	
			LI, LD/RR,PS,FCFS…	LI, LD/RR,PS,FCFS…
Classe (r)	**Tipo**	λ_r **(tps)**	$D_{CPU,r}\ (sec)$	$D_{Disk,r}\ (sec)$
1 (semplice)	Aperto	0.675		
2 (medio)	Aperto	0.375		
3 (complesso)	Aperto	0.450		

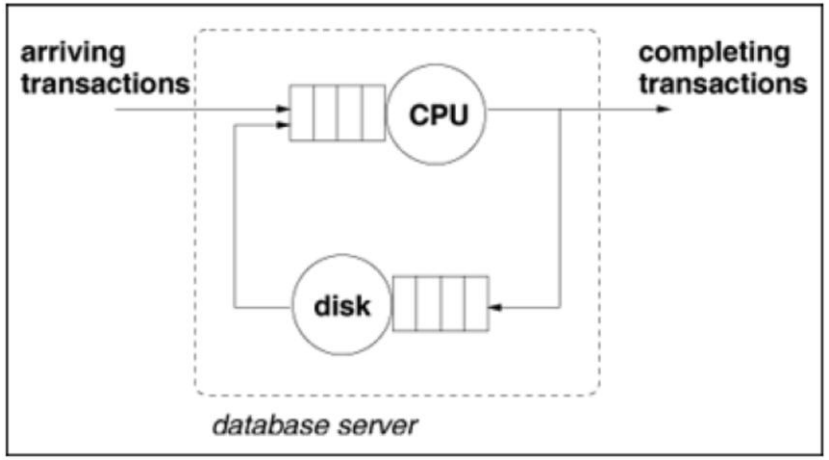

Classe di servizio	Percentuale sul totale	Tempo medio di CPU (sec)	Numero medio di I/O
Semplice	45%	0.04	5.5
Medio	25%	0.18	28.9
Complesso	30%	1.20	85.0

Supponiamo che il centro CPU venga visitato due volte per l'elaborazione di ciascuna richiesta.

K=2; R=3; Open QN			Tipo di Coda / Politica di Scheduling	
			LI/PS	LI/RR
Classe (r)	**Tipo**	**λ_r (tps)**	$D_{CPU,r}\ (sec)$	$D_{Disk,r}\ (sec)$
1 (semplice)	Aperto	0.675		
2 (medio)	Aperto	0.375		
3 (complesso)	Aperto	0.450		

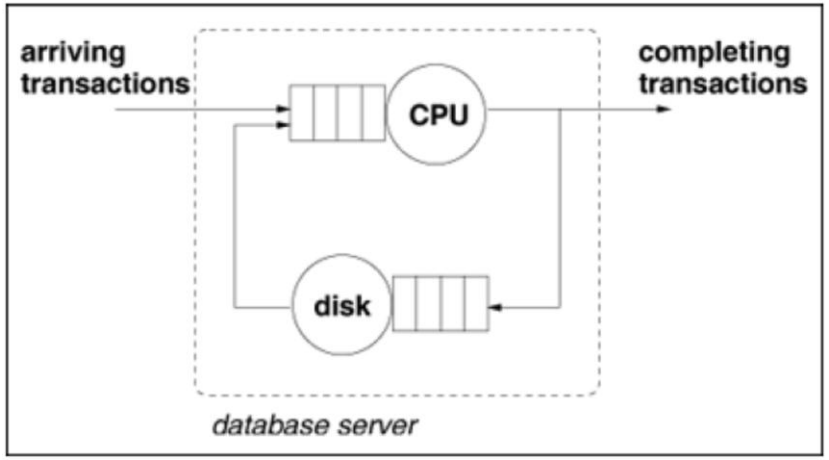

Classe di servizio	Percentuale sul totale	Tempo medio di CPU (sec)	Numero medio di I/O
Semplice	45%	0.04	5.5
Medio	25%	0.18	28.9
Complesso	30%	1.20	85.0

Supponiamo che il tempo medio di esecuzione di un'operazione di I/O sia pari a 0.01 sec.

K=2; R=3; Open QN			Tipo di Coda / Politica di Scheduling	
			LI/PS	LI/RR
Classe (r)	**Tipo**	**λ_r (tps)**	$D_{CPU,r}$ (sec)	$D_{Disk,r}$ (sec)
1 (semplice)	Aperto	0.675	0.08	
2 (medio)	Aperto	0.375	0.36	
3 (complesso)	Aperto	0.450	2.4	

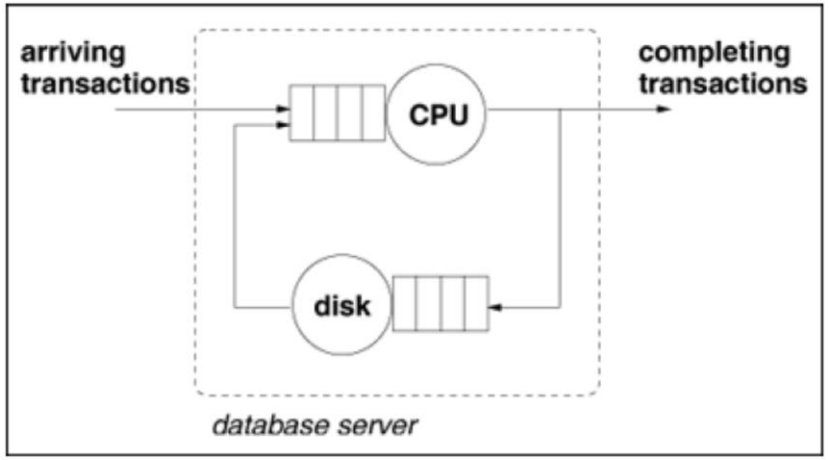

Classe di servizio	Percentuale sul totale	Tempo medio di CPU (sec)	Numero medio di I/O
Semplice	45%	0.04	5.5
Medio	25%	0.18	28.9
Complesso	30%	1.20	85.0

Supponiamo che il tempo medio di esecuzione di un'operazione di I/O sia pari a 0.01 sec.

K=2; R=3; Open QN			Tipo di Coda / Politica di Scheduling	
			LI/PS	LI/RR
Classe (r)	**Tipo**	**λ_r (tps)**	$D_{CPU,r}\ (sec)$	$D_{Disk,r}\ (sec)$
1 (semplice)	Aperto	0.675	0.08	5.5x0.01=0.055
2 (medio)	Aperto	0.375	0.36	28.9x0.01=0.289
3 (complesso)	Aperto	0.450	2.4	85x0.01=0.850

RISOLVIAMO IL NOSTRO PRIMO PROBLEMA

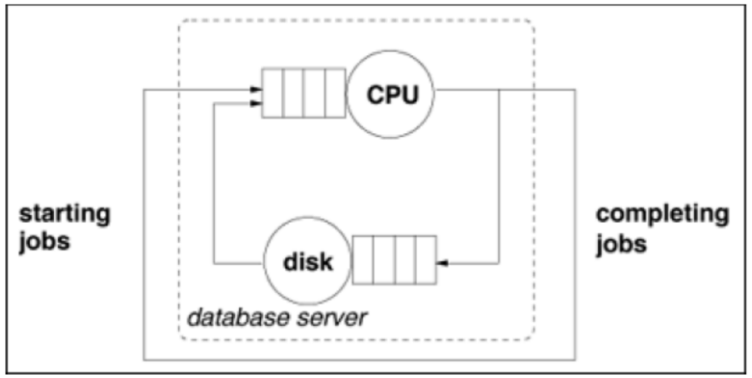

Due applicazioni batch vengono eseguite contemporaneamente di notte.

Nessun'altra attività è presente.

Una delle applicazioni genera report delle vendite, l'altra report di marketing.

Entrambe sono applicazioni multithread

- 5 thread per la prima applicazione
- 10 thread per la seconda applicazione
- Ogni thread genera un report

Sapendo che:

- La prima applicazione ha un service demand di 45 sec per la CPU e 50 sec per il disco
- La seconda applicazione ha un service demand di 80 sec per la CPU e 96 sec per il disco

Qual è il throughput atteso delle due applicazioni?

ESERCIZIO 1

Una connessione da 20Mbps è utilizzata per trasmettere pacchetti lunghi 1500 byte.

- Qual è il *service demand* di un singolo pacchetto su questa connessione?
- Service demand: tempo medio totale speso da una transazione in una data risorsa

$$D = \frac{1500}{20*1024*1024/8} = 5.72 \times 10^{-4}\ sec$$

ESERCIZIO 2

Un sistema esegue:

- Un workload di transazioni che vengono ricevute al tasso di 10 tps
- Un workload di richieste inviate da 50 client, che attendono una risposta prima di inviare una nuova richiesta

Che tipo di QN dovremmo usare per modellare il sistema?

QN mista

ESERCIZIO 3

Service demand: tempo medio totale speso da una transazione in una data risorsa

Un DB Server dispone di due dischi identici.

- Il service demand sul disco 1 è pari a 100msec
- Il service demand sul disco 2 è pari a 150msec

Come variano i service demand nei seguenti scenari?

- Disco 1 è sostituito da un disco che è del 40% più veloce
  - **100ms → 10 tps; 40% più veloce → 14 tps; nuovo service demand su disco 1: 1/14=71.4ms**
- L'opzione di log del DBMS viene abilitata. Un record di log viene generato su disco 2 per ogni transazione di UPDATE, che sono il 30% del totale. Il salvataggio di un log richiede 15msec.
  - **Service demand su disco 1 invariato; service demand su disco 2: 150msec + 0.3 * 15msec = 154.5msec**

ESERCIZIO 4

Il workload di un DBMS è decomposto in 4 classi: *semplice, medio, complesso, aggiornamento,* con tassi di arrivo e service demand come riportato in tabella

	Semplice	Medio	Complesso	Update
Tasso arrivo (tps)	0.2	0.3	0.2	0.1
Service Demand (msec)				
CPU	0.15	0.3	0.45	0.7
Disk 1	0.2	0.35	0.55	0.3
Disk 2	0.1	0.3	0.6	0.2

Siamo interessati a rispondere alle seguenti domande:

- Qual è l'effetto sul tempo di risposta delle transazioni *semplici* se il loro tasso di arrivo aumenta del 50%?
- Qual è l'effetto sul tempo di risposta delle transazioni di *update* se il loro tasso di arrivo aumenta del 25%?
- Qual è l'effetto sul tempo di risposta delle transazioni semplici se le transazioni di *update* vengono eseguite su una macchina differente?

Non sappiamo ancora rispondere a queste domande. Però è evidente che le classi *medio* e *complesso* non servono in questa analisi. Come possiamo aggregarle per formare un'unica classe?

ESERCIZIO 4 (2)

	Semplice	Medio	Complesso	Update
Tasso arrivo (tps)	0.2	0.3	0.2	0.1
Service Demand (msec)				
CPU	0.15	0.3	0.45	0.7
Disk 1	0.2	0.35	0.55	0.3
Disk 2	0.1	0.3	0.6	0.2

	Semplice	Nuova Classe (Medio + Complesso)	Update
Tasso arrivo (tps)	0.2	**0.3 + 0.2 = 0.5**	0.1
Service Demand (msec)			
CPU	0.15	**0.6x0.3 + 0.4x0.45 =0.36**	0.7
Disk 1	0.2	**0.6x0.35 + 0.4x0.55 =0.43**	0.3
Disk 2	0.1	**0.6x0.3 + 0.4x0.6 =0.42**	0.2