TECNOLOGIE E ARCHITETTURE PER LA GESTIONE DEI DATI
A.A. 2024/2025

MODELLAMENTO DI SISTEMI: ASPETTI QUANTITATIVI

Capitolo 3

P. ATZENI, L. BELLOMARINI, S. IANNUCCI

INTRODUZIONE

Nelle lezioni precedenti abbiamo visto come poter descrivere alcuni sistemi utilizzando il formalismo delle *reti di code*

Non sappiamo però ancora risolvere problemi complessi dove non tutti i dati sono immediatamente a disposizione. Questi ci serviranno a rispondere a domande fondamentali, quali:

- Qual è il tempo di risposta al variare del carico?
- Qual è il throughput del sistema?
- Qual è l'utilizzazione del sistema?
- Cosa succede se faccio delle modifiche?

Ci concentriamo oggi quindi a comprendere le relazioni tra le diverse quantità in gioco con un approccio chiamato *analisi operazionale*.

PROBLEMA

Supponiamo che, durante un minuto di osservazione di un sistema:

- La CPU è occupata per 36 secondi
- Sono state richieste un totale di 1800 transazioni
- Sono state completate un totale di 1800 transazioni

Qual è il tempo medio di servizio per transazione? Qual è l'utilizzazione delle risorse? Qual è il throughput del sistema?

VARIABILI OPERAZIONALI

Prima di risolvere il problema, dobbiamo introdurre un po' di notazione:

- T: lunghezza del periodo di osservazione
- K: numero di risorse nel sistema
- B_i: tempo in cui la risorsa i è occupata (busy) nel periodo di osservazione T
- A_i: numero totale di richieste di servizio (o arrivi) alla risorsa i nel periodo di osservazione T
- A_0: numero totale di richieste arrivate al sistema nel periodo di osservazione T
- C_i: numero totale di richieste evase dalla risorsa i nel periodo di osservazione T
- C_0: numero totale di richieste evase dal sistema nel periodo di osservazione T

Queste quantità vengono comunemente chiamate ***variabili operazionali***, e solitamente possiamo ***misurarle direttamente.***

METRICHE DERIVATE

A partire dalle variabili operazionali, possiamo derivare ulteriori metriche:

- $S_i = \frac{B_i}{C_i}$: tempo medio di servizio per la risorsa i
- $U_i = \frac{B_i}{T}$: utilizzazione della risorsa i
- $X_i = \frac{C_i}{T}$: throughput della risorsa i
- $\lambda_i = \frac{A_i}{T}$: tasso degli arrivi alla risorsa i
- $X_0 = \frac{C_0}{T}$: throughput del sistema

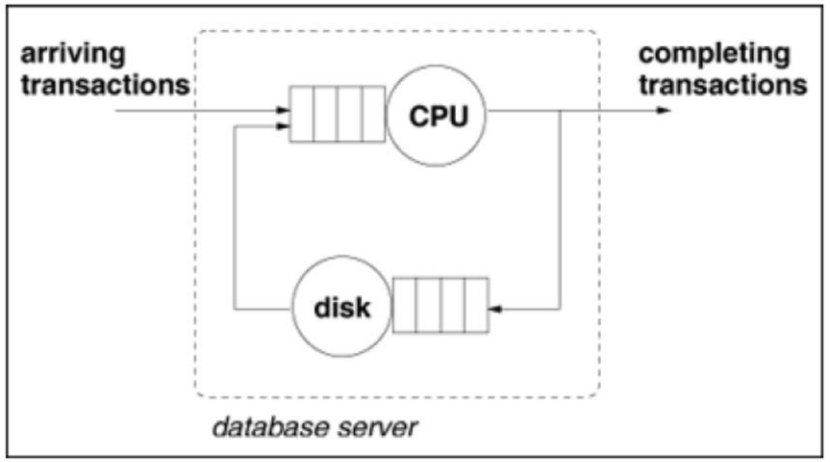

RISOLVIAMO IL PROBLEMA DI PRIMA

Supponiamo che, durante un minuto di osservazione ($T = 60$ sec) di un sistema:

- La CPU è occupata per 36 secondi
  - $B_{CPU} = 36\ sec$
- Sono state richieste un totale di 1800 transazioni
  - $A_{CPU} = A_0 = 1800\ transazioni$
- Sono state completate un totale di 1800 transazioni
  - $C_{CPU} = C_0 = 1800\ transazioni$

Qual è il tempo medio di servizio per transazione?

- $S_{CPU} = \frac{B_{CPU}}{C_{CPU}} = \frac{36}{1800} = \frac{1}{50}$ sec per transazione

Qual è l'utilizzazione delle risorse?

- $U_{CPU} = \frac{B_{CPU}}{T} = \frac{36}{60} = 60\%$

Qual è il throughput del sistema?

- $X_0 = X_{CPU} = \frac{C_0}{T} = \frac{1800}{60} = 30\ tps$

SUPPORTO A CLASSI MULTIPLE

Abbiamo visto come in molti casi sia fondamentale poter dividere il workload in più classi.

La notazione che abbiamo visto può essere facilmente estesa per supportare classi multiple introducendo $R = \#classi$ ed aggiungendo un indice alle variabili. Esempio:

$U_{i,r}$: utilizzazione della risorsa i dovuta alla classe r

$X_{0,r}$: throughput del sistema rispetto alla classe r

… e così via.

LEGGI OPERAZIONALI

Vediamo ora più nel dettaglio legami tra le varie quantità di cui abbiamo discusso. In particolare, introdurremo:

- La legge dell'utilizzazione (Utilization Law)
- La legge del service demand (Service Demand Law)
- La legge del flusso forzato (Forced Flow Law)
- La legge di Little (Little's Law)
- La legge del tempo di risposta interattivo (Interactive Response Time Law)

LEGGE DELL'UTILIZZAZIONE (UTILIZATION LAW)

Abbiamo già definito: $U_i = \frac{B_i}{T}$.

Matematicamente, possiamo moltiplicare sia il numeratore che il denominatore per la stessa quantità C_i. Otteniamo quindi: $U_i = \frac{B_i}{T} = \frac{B_i C_i}{C_i T}$

Avevamo però già definito:

- $S_i = \frac{B_i}{C_i} \quad e \quad X_i = \frac{C_i}{T}$

Possiamo quindi riscrivere $\boldsymbol{U_i = S_i \times X_i}$

- Se la risorsa i è in equilibrio ed abbiamo che il numero di arrivi è uguale al numero di completamenti ($A_i = C_i$), allora abbiamo anche che $\lambda_i = X_i$, e quindi $U_i = S_i \times \lambda_i$
- Se la risorsa i dispone di m server, come nel caso di una coda multiprocessore, allora $U_i = \frac{S_i \times X_i}{m}$
- Se ci troviamo in una situazione multi-classe, allora $U_{i,r} = \frac{S_{i,r} \times X_{i,r}}{m}$

ESEMPIO 1

La banda di un canale di comunicazione è pari a **56 Kbps**. Questo è utilizzato per trasmettere pacchetti da **1500 byte** al tasso di **3 pacchetti/secondo**.
Qual è l'utilizzazione del link?

- Primo passo: identificazione delle variabili operazionali fornite o che possono essere misurate
  - Ci viene dato il throughput: 3 pps. Quindi: $\lambda_0 = X_0 = 3\ pps$
  - Ci viene detto anche che, ipoteticamente, il sistema può evadere 56 Kbps.
- Un modo per calcolare l'utilizzazione è con l'utilization law: $U_0 = S_0 \times X_0$
  - X_0 ce l'abbiamo. Ci manca S_0, ma possiamo facilmente ottenerlo considerando che:
    Ogni pacchetto ha una dimensione di 1500 bytes ➔ 12000 bits. Quindi, ci vogliono $\frac{12000}{56000} = 0.214\ sec$ per trasmettere un pacchetto. Quindi, $S_0 = 0.214\ sec$
- Quindi: $U_0 = S_0 \times X_0 = 0.214 \times 3 = 0.642 = 64.2\%$

ESEMPIO 2

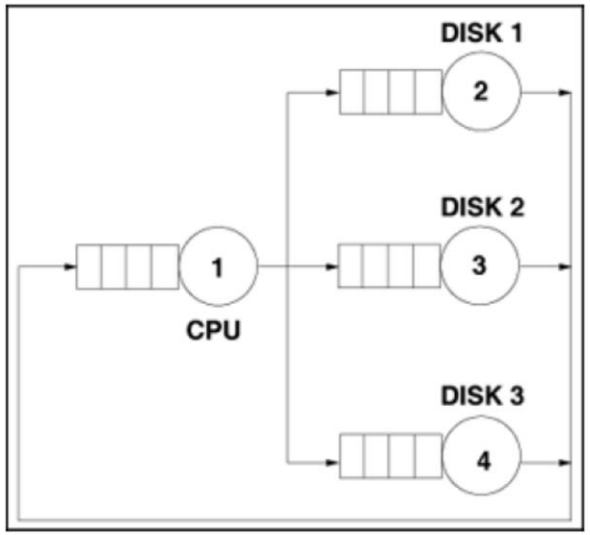

Abbiamo un computer con una CPU e tre dischi per eseguire un DBMS.

- Assumiamo che tutte le transazioni abbiano carico simile sulle risorse ➔ non c'è bisogno di creare classi
- Assumiamo che il DBMS sia sottoposto ad un carico batch ➔ modelliamo come sistema chiuso.
- Le risorse sono numerate da 1 a 4 come in figura
- Durante un tempo di osservazione di 1h $(T = 1h)$ vengono prese le seguenti misurazioni:
  - Numero di transazioni completate: 13680 ➔ $C_0 = 13680$
  - Numero di letture e scritture al secondo ed utilizzazione come in tabella
- Qual è il tempo di servizio medio per richiesta su ogni disco?
  - $U = S \times X \Rightarrow S = \frac{U}{X}$
  - $S_2 = \frac{0.3}{32} = 0.0094s; \quad S_3 = \frac{0.41}{36} = 0.0114s; \quad S_4 = \frac{0.54}{50} = 0.0108s$
- Qual è il throughput del DMBS?
  - $X_0 = \frac{C_0}{T} = \frac{13680}{3600} = 3.8\ tps$

Disk	w/sec	r/sec	IOPS	U
2	24	8	32	0.3
3	28	8	36	0.41
4	40	10	50	0.54

SERVICE DEMAND

Il Service Demand D_i è un concetto fondamentale nel modellamento delle prestazioni.

D_i Indica il tempo medio totale speso da una richiesta nella risorsa i.

- Una richiesta può passare per (visitare) una data risorsa più volte prima di essere evasa
- Il service demand è pari alla somma dei singoli tempi di visita, fino ad evasione della richiesta
- Il service demand è medio, perché si prende la media su tante richieste

Nota: il service demand, per definizione, ***non include il tempo di coda.***

Se ci troviamo in presenza di un modello multi-classe, allora il service demand per la risorsa i e classe r è espresso come $D_{i,r}$

ESEMPIO DI SERVICE DEMAND

Consideriamo le sei transazioni riportate in tabella. Ognuna esegue tre operazioni di I/O su un dato disco.

- I numeri rappresentano il tempo di I/O in ms per una data operazione ed una data transazione.
- In altre parole, rappresentano il tempo di visita del centro *disco*.
- Il service demand è dato dalla media dell'ultima riga ed è pari a 36.2 ms

	Transaction No.					
I/O n.	1	2	3	4	5	6
1	10	15	13	10	12	14
2	12	12	12	11	13	12
3	11	14	11	11	11	13
Sum	*33*	*41*	*36*	*32*	*36*	*39*

LEGGE DEL SERVICE DEMAND (SERVICE DEMAND LAW)

I service demand sono importanti parametri di input per i modelli QN.

Se non dovessero essere forniti esplicitamente, possono essere ricavati con la *service demand law* a partire dall'*utilizzazione del centro* e dal *numero di richieste evase* dal sistema in un determinato intervallo temporale.

$$D_i = \frac{U_i \times T}{C_0} = \frac{U_i}{C_0/T} = \frac{U_i}{X_0}$$

Esempio: Supponiamo che un sistema sia osservato per T=1s, che nel periodo di osservazione vengano completate 4 richieste ($C_0 = 4$), e che la risorsa CPU abbia avuto un'utilizzazione media del 60%. Allora abbiamo che il service demand della CPU è pari a: $D_{CPU} = \frac{0.6 \times 1}{4} = 0.15s$

Questa relazione può essere riscritta intuitivamente anche come $D_i = S_i \times V_i$

La versione multi-classe della service demand law, per la risorsa i e la classe r è:

$$D_{i,r} = \frac{U_{i,r}}{X_{0,r}} = S_{i,r} \times V_{i,r}$$

ESEMPIO 3

Un web server viene monitorato per **10 minuti,** e viene osservato che la sua **CPU è occupata per il 90% del tempo.**

I log del web server rivelano che in questo intervallo vengono **processate 30000 richieste.**

Qual è il service demand della CPU?

$$D_{CPU} = \frac{U_{CPU}}{X_0}$$

Abbiamo già $U_{CPU} = 90\%$

$$X_0 = \frac{30000}{600} = 50\ req/sec$$

$$D_{CPU} = \frac{0.9}{50} = 0.018\ sec/req$$

ESEMPIO 4

Assumendo **un'utilizzazione di CPU pari al 35%**, quali sono i service demand di CPU e dei tre dischi dell'esempio 2?

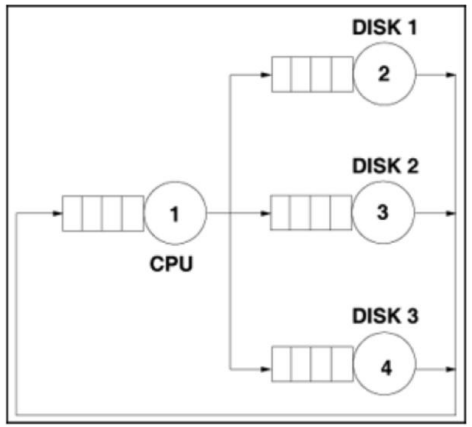

Disk	w/sec	r/sec	IOPS	U
2	24	8	32	0.3
3	28	8	36	0.41
4	40	10	50	0.54

$C_0 = 13680$ transazioni
$T = 1h$

Avevamo calcolato il throughput del sistema: $X_0 = \frac{C_0}{T} = \frac{13680}{3600} = 3.8\ tps$

$$D_i = \frac{U_i}{X_0} \Rightarrow D_1 = \frac{0.35}{3.8} = 0.092s, D_2 = \frac{0.3}{3.8} = 0.079s, D_3 = \frac{0.41}{3.8} = 0.108s, D_4 = \frac{0.54}{3.8} = 0.142s$$