STUDIO DEI LIMITI DELLE PRESTAZIONI

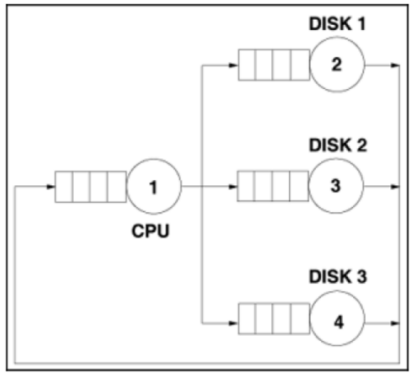

Con gli strumenti che abbiamo finora studiato possiamo calcolare:

- L'upper bound sul throughput
- Il lower bound sul tempo di risposta

Necessario individuare la risorsa *collo di bottiglia (bottleneck)*, e su quest'ultima effettuare un rapido studio

- La risorsa bottleneck è quella con la più alta utilizzazione o, equivalentemente, il più alto service demand.

Con riferimento all'Esempio 2, avevamo calcolato i service demand riportati in tabella

Risorsa	Service Demand (sec)
CPU	0.092
DISK1	0.079
DISK2	0.108
DISK3	0.142

CALCOLO DEL THROUGHPUT MASSIMO

Risorsa	Service Demand (sec)
CPU	0.092
DISK1	0.079
DISK2	0.108
DISK3	0.142

Utilizzando la Service Demand Law, possiamo calcolare l'utilizzazione:

$U_i = D_i \times X_0$ o, alternativamente, il throughput ad un certo livello di utilizzazione:

$$X_0 = U_i / D_i$$

Quindi, il throughput massimo X_0 ottenibile dal sistema è pari a quello della risorsa bottleneck quando questa raggiunge il 100% di utilizzazione. Abbiamo quindi:

$$X_0 = \frac{1}{0.142} = 7.042\ tps$$

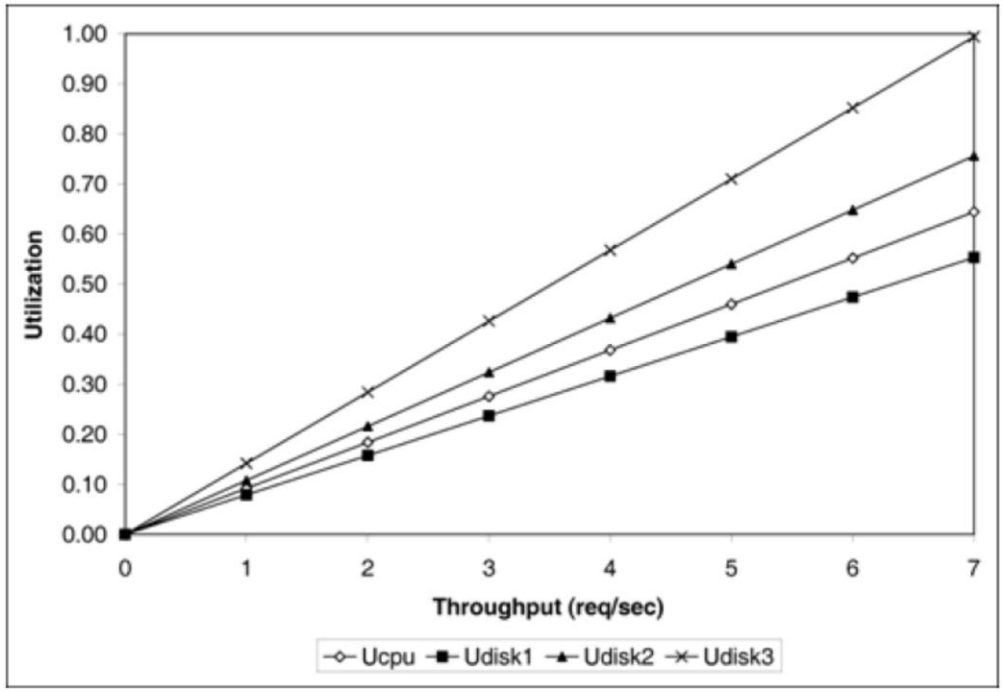

UPPER BOUND SUL THROUGHPUT CON CARICO ELEVATO

Quindi, più in generale, possiamo stabilire la seguente relazione sul throughput:

$$X_0 = \frac{U_i}{D_i} \leq \frac{1}{D_i} \ \forall i$$

Oppure, in modo più compatto: $X_0 \leq \frac{1}{\max\{D_i\}}$

Questa relazione è nota come *l'upper bound asintotico sul throughput* ***in condizioni di carico elevato.***

- Vuol dire che abbiamo il sistema in saturazione, e che è molto probabile che alcune richieste dovranno accodarsi nel centro collo di bottiglia.

UPPER BOUND THROUGHPUT CON CARICO LEGGERO

Calcoliamo ora *l'upper bound asintotico sul throughput* ***in condizioni di carico leggero***. In altre parole, il throughput massimo ottenibile **senza che nessuna richiesta venga mai accodata**.

- Se nessuna richiesta viene mai accodata, allora il tempo di risposta è pari a: $\mathrm{R} = (\sum_i D_i)$
- Per la legge di Little, abbiamo che: $N = R \times X_0 \geq (\sum_i D_i) \times X_0$
- Quindi, $X_0 = \frac{N}{(\sum_i D_i)}$ è l'upper bound sul throughput in condizioni di carico leggero.
- Quindi, combinando upper bound leggero e pesante, otteniamo: $X_0 \leq min\left[\frac{1}{\max\{D_i\}}, \frac{N}{\sum_i D_i}\right]$

STUDIO DEI LIMITI DELLE PRESTAZIONI (5)

$$X_0 \leq min\left[\frac{1}{\max\{D_i\}}, \frac{N}{\sum_i D_i}\right]$$

Cosa succede se sostituiamo DISK3 (che era collo di bottiglia) con uno il doppio più veloce?

- Aumento del throughput massimo del 32%

Risorsa	Service Demand (sec)
CPU	0.092
DISK1	0.079
DISK2	0.108
DISK3	0.142 → 0.71

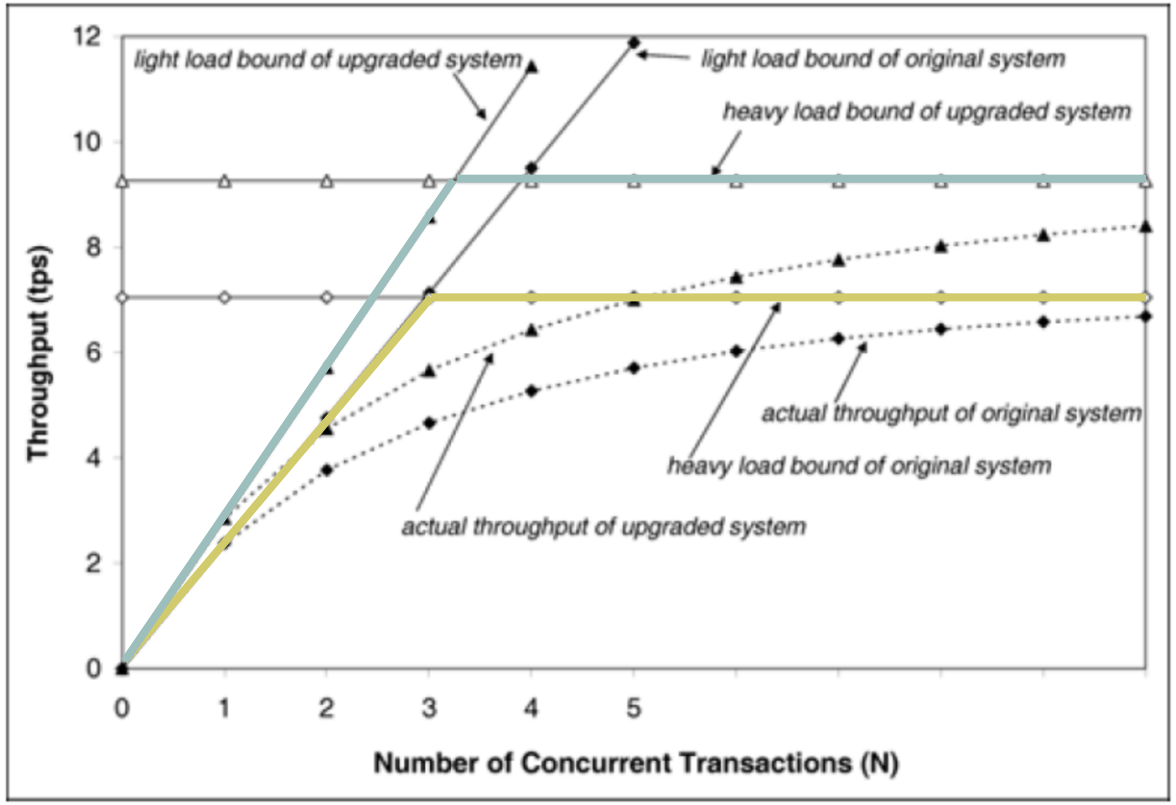

ESEMPIO 10

Consideriamo il sistema di Esempio 2

- Quali dovrebbero essere i service demand $D_{DISK1}, D_{DISK2}, D_{DISK3}$ per massimizzare il throughput al contempo mantenendo costante la somma dei service demand sui 3 dischi?
- In altre parole, vogliamo massimizzare il throughput bilanciando il carico sui 3 dischi
- $D_{DISKS} = \frac{D_{DISK1}+D_{DISK2}+D_{DISK3}}{3} = 0.1097$
- Otteniamo quindi: $X_0 = \frac{1}{0.1097} = 9.12\ tps$
  - Un aumento di throughput del 29.5% solo ribilanciando il lavoro dei dischi

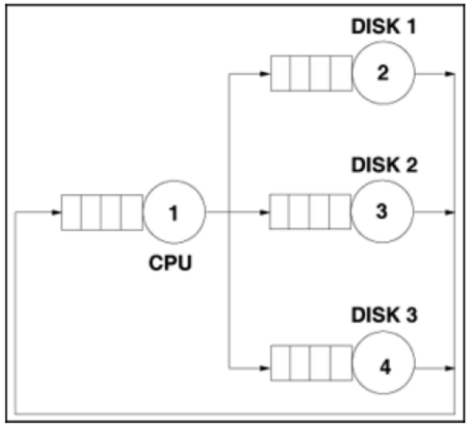

Risorsa	Service Demand (sec)
CPU	0.092
DISK1	0.079 → 0.1097
DISK2	0.108 → 0.1097
DISK3	0.142 → 0.1097

ESEMPIO 11

Possiamo infine calcolare il lower bound sul tempo di risposta con la legge di Little:

$$N = R \times X_0 \Rightarrow R = N/X_0$$

$$X_0 \leq min\left[\frac{1}{\max\{D_i\}}, \frac{N}{\sum_i D_i}\right] \Rightarrow$$

$$\Rightarrow R \geq \frac{N}{min\left[\frac{1}{\max\{D_i\}}, \frac{N}{\sum_i D_i}\right]} =$$

$$= \max[N \times \max\{D_i\}, \sum_i D_i]$$

Nel caso specifico del sistema di Esempio 2, abbiamo: $R \geq \max[N \times 0.142, 0.421]$

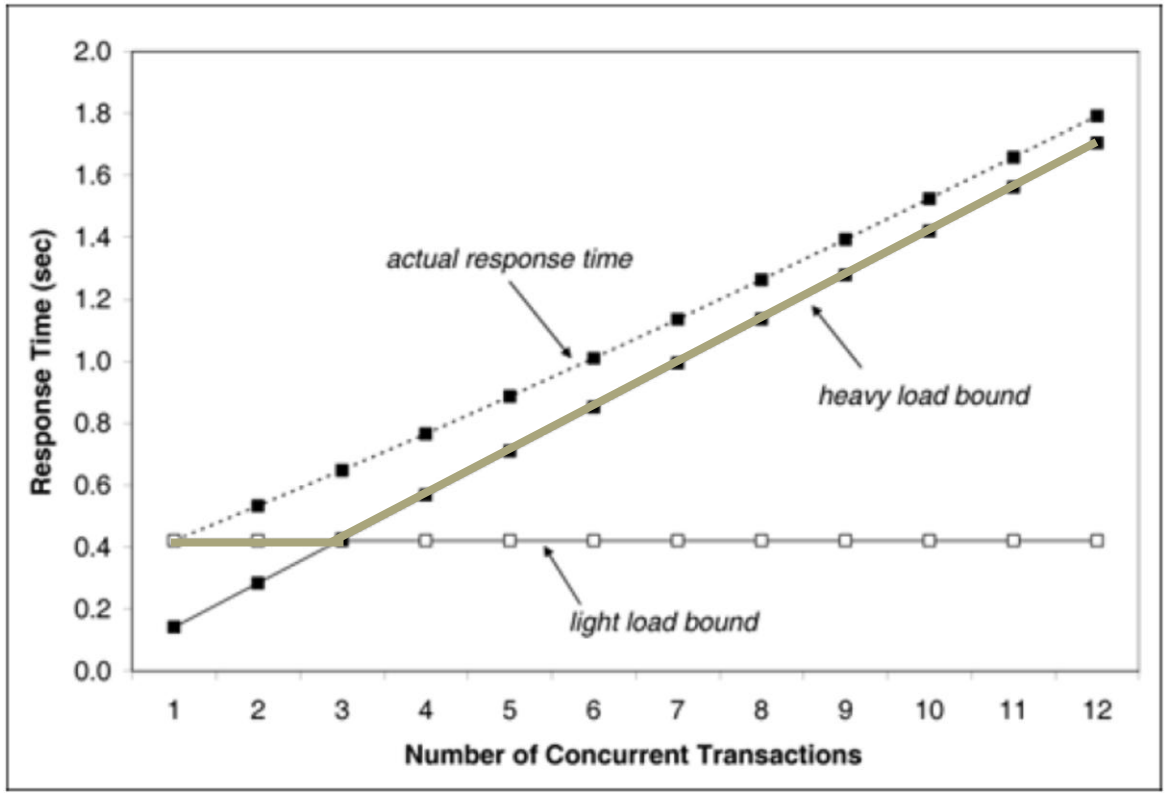

ESEMPIO 12

Un web server composto da una CPU ed un disco è stato monitorato per **un'ora.**

- Dall'analisi si evince che il workload può essere caratterizzato in **due tipi di richieste**: quelle per file HTML e quelle per immagini
  - In particolare, si osservano **14040** richieste per file HTML e **1034** richieste per immagini
- Dai log si evince inoltre che, in media, **i file HTML pesano 3000 byte** e **le immagini 15000 byte**
- Il **service demand medio del disco è pari a 12ms** per un blocco da 1000 byte
- Supponendo che il service demand della CPU sia rappresentabile (in questo esempio) dall'espressione: $D_{CPU} = 0.008 + 0.002 \times RequestSize$, dove *RequestSize* è il numero di blocchi da 1000 byte
- Il tasso degli arrivi per-classe sia pari a:
  - $\lambda_{HTML} = \frac{14040}{3600} = 3.9\, req/s$
  - $\lambda_{IMG} = \frac{1034}{3600} = 0.29\, req/s$

ESEMPIO 12 (2)

Come modelliamo questo sistema?

- QN mono-classe o multi-classe?
  - Abbiamo identificato due classi ben precise, quindi multi-classe con due classi
- QN aperta o chiusa?
  - Dipende da come è descritto il workload. Dipende da un numero fissato di utenti?
  - No, quindi QN aperta

Una volta capito come progettare la QN, questa va parametrizzata. Ci servono i service demand di CPU e disco.

- $D_{CPU,HTML} = 0.008 + 0.002 \times 3 = 0.014s$
- $D_{CPU,IMG} = 0.008 + 0.002 \times 15 = 0.038s$
- $D_{DISK,HTML} = 0.012 \times 3 = 0.036s$
- $D_{DISK,IMG} = 0.012 \times 15 = 0.18s$

ESEMPIO 12 (3)

	HTML	IMG
Arrival rate	3.9	0.29
Service Demands		
CPU	0.014	0.038
Disk	0.036	0.18

Siamo interessati a conoscere:

- Utilizzazione per-classe di CPU e disco

Service demand law: $D_i = \frac{U_i}{X_0} \Rightarrow U_i = D_i \times X_0$

- $U_{CPU,HTML} = 0.014 \times 3.9 = 5.46\%$; $U_{CPU,IMG} = 0.038 \times 0.29 = 1.1\%$
- $U_{DISK,HTML} = 0.036 \times 3.9 = 14.04\%$; $U_{DISK,IMG} = 0.18 \times 0.29 = 5.22\%$

Siamo in grado di sostenere un carico 5 volte maggiore?

- $U_{CPU} = 6.56\% \Rightarrow U_{CPU-5\times} = 32.8\%$
- $U_{DISK} = 19.26\% \Rightarrow U_{DISK-5\times} = 96.3\%$

ESEMPIO 13

	HTML	IMG
N	14	6
Service Demands		
CPU	0.014	0.038
Disk	0.036	0.18

Consideriamo il sistema precedente. Se il workload fosse espresso in questi termini:

- Osservando il sistema, c'è sempre al suo interno una media di 14 richieste HTML e 6 richieste per immagini

Come cambierebbe il modello QN?

- Numero di job all'interno del sistema costante
- → QN chiusa.

Calcolare utilizzazione e throughput al variare di N

ESERCIZIO 5

Un sistema è monitorato per un'ora

- 5400 transazioni processate
- Tempo di servizio medio del disco pari a 30ms per visita
- Disco visitato in media 3 volte per ogni transazione

Qual è l'utilizzazione del disco?

- Utilization law: $U_i = X_i \times S_i$
  - Abbiamo S_{DISCO}, ci manca X_{DISCO} (ma abbiamo X_0 e V_{DISCO})
- Forced flow law: $X_i = V_i \times X_0 \Rightarrow \mathrm{X_{DISCO}} = 3 \times \frac{5400}{3600} = 4.5\,\frac{req}{s}$
- $U_{DISCO} = X_{DISCO} \times S_{DISCO} = 4.5 \times 0.03 = 13.5\%$

ESERCIZIO 7

Un file server viene monitorato per 60 minuti

- 7200 richieste completate
- Utilizzazione del disco pari a 30%
- Service time pari a 30ms per richiesta

Qual è il numero medio di accessi al disco per ogni richiesta di file?

- Forced flow law: $X_i = V_i \times X_0$
  - Abbiamo $X_0 = \frac{7200}{3600} = 2\ req/s$
  - Ci manca X_i
- Utilization law: $U_i = X_i \times S_i \Rightarrow X_i = \frac{0.3}{0.03} = 10\ req/s$
- $\Rightarrow V_i = \frac{X_i}{X_0} = \frac{10}{2} = 5\ visite$

ESERCIZIO 9

Un sistema ha 1 CPU e 2 dischi ed è monitorato per 1h.

- Utilizzazione di CPU pari a 32%; utilizzazione di disco1 pari a 60%
- Ogni transazione fa 5 operazioni di I/O su disco1 e 8 su disco2
- Il service time medio di disco1 è pari a 30ms; quello di disco2 è pari a 25ms

Calcolare il throughput del sistema.

- Forced Flow law: $X_i = V_i \times X_0 \Rightarrow X_0 = \frac{X_i}{V_i}$
  - Abbiamo V_i per i dischi, ma non abbiamo X_i
- Utilization law: $U_i = X_i \times S_i \Rightarrow X_{DISCO1} = \frac{0.6}{0.03} = 20\, req/sec$
- Quindi: $X_0 = \frac{X_{DISCO1}}{V_{DISCO1}} = \frac{20}{5} = 4\, req/sec$

Calcolare l'utilizzazione di disco2

- Abbiamo il throughput del sistema, quindi possiamo riapplicare la forced flow law per ottenere $X_{DISCO2} = 8 \times 4 = 32\, req/sec$
- Quindi possiamo ottenere l'utilizzazione: $U_{DISCO2} = X_{DISCO2} \times S_{DISCO2} = 32 \times 0.025 = 80\%$

Calcolare i service demand medi per CPU, disco1, disco2.

- Service demand law: $D_i = V_i \times S_i = U_i / X_0$
  - $D_{CPU} = \frac{0.32}{4} = 0.08s; D_{DISCO1} = 5 \times 0.03 = 0.15s; D_{DISCO2} = 8 \times 0.025 = 0.2s$

Usando JMT, calcolare throughput, response time, media della lunghezza delle code con N=1, …, 4

Basandoci sui risultati ottenuti, approssimativamente quanto valeva N nel periodo di osservazione?

ESERCIZIO 10

Un sistema interattivo ha 50 terminali

- Think time degli utenti pari a 5s
- Utilizzazione di un disco pari a 60% e service time pari a 30ms
- Ogni richiesta necessita in media di 4 accessi al disco

Qual è il tempo di risposta del sistema?

- Interactive Response Time Law: $R = \frac{M}{X_0} - Z$
  - Abbiamo M e Z, ci manca X_0
- Forced flow law: $X_i = V_i \times X_0 \Rightarrow X_0 = \frac{X_i}{V_i}$
  - Abbiamo V_i, ci manca X_i
- Utilization law: $U_i = X_i \times S_i \Rightarrow X_i = \frac{U_i}{S_i} = \frac{0.6}{0.03} = 20\, req/sec$
- Quindi, $X_0 = \frac{20}{4} = 5\, req/sec$
- Ed infine: $R = \frac{50}{5} - 5 = 5s$